

# Машинное обучение

## Лекция 7. Логистическая регрессия и SVM

Виктор Кантор

# План

- I. Напоминание линейных моделей
- II. Логистическая регрессия
- III. Метод опорных векторов (Support Vector Machine)
- IV. Подробнее о регуляризации
- V. Где применяют линейные модели

# I. Напоминание линейных моделей

# Линейная регрессия

$$a(x) = \langle w, x \rangle + w_0$$

# Линейная регрессия

$$a(x) = \langle w, x \rangle + w_0$$

$$Q = \sum_{i=1}^N L(y_i, a(x_i))$$

# Линейная регрессия

$$a(x) = \langle w, x \rangle + w_0$$

$$Q = \sum_{i=1}^N L(y_i, a(x_i))$$

$$L(y_i, a(x_i)) = (y_i - a(x_i))^2$$

# Линейная регрессия

$$a(x) = \langle w, x \rangle + w_0$$

$$Q = \sum_{i=1}^N L(y_i, a(x_i))$$

$$L(y_i, a(x_i)) = (y_i - a(x_i))^2$$

$$L(y_i, a(x_i)) = |y_i - a(x_i)|$$

# Линейная классификация

$$a(x) = \begin{cases} 1, & \text{если } f(x) > 0 \\ -1, & \text{если } f(x) < 0 \end{cases}$$

$$f(x) = w_0 + w_1x_1 + \dots + w_nx_n$$




# Линейная классификация

$$a(x) = \begin{cases} 1, & \text{если } f(x) > 0 \\ -1, & \text{если } f(x) < 0 \end{cases}$$

$$f(x) = w_0 + w_1x_1 + \dots + w_nx_n = w_0 + \langle w, x \rangle$$

Геометрическая интерпретация:  
разделяем классы плоскостью




# Линейная классификация

$$a(x) = \begin{cases} 1, & \text{если } f(x) > 0 \\ -1, & \text{если } f(x) < 0 \end{cases}$$

$$f(x) = \langle w, x \rangle$$

Геометрическая интерпретация:  
разделяем классы плоскостью



# Отступ (margin)

Отступом алгоритма  $a(x) = \text{sign}\{f(x)\}$  на объекте  $x_i$  называется величина  $M_i = y_i f(x_i)$

( $y_i$  - класс, к которому относится  $x_i$ )

$$M_i \leq 0 \Leftrightarrow y_i \neq a(x_i)$$

$$M_i > 0 \Leftrightarrow y_i = a(x_i)$$

# Функция потерь

$$Q(w) = \sum_{i=1}^{\ell} [M_i(w) < 0]$$

# Функция потерь


$$Q(w) = \sum_{i=1}^{\ell} [M_i(w) < 0] \leq \tilde{Q}(w) = \sum_{i=1}^{\ell} \mathcal{L}(M_i(w)) \rightarrow \min_w;$$

Функция эмпирического риска

Функция потерь

# Функция потерь


$$Q(w) = \sum_{i=1}^{\ell} [M_i(w) < 0] \leq \tilde{Q}(w) = \sum_{i=1}^{\ell} \mathcal{L}(M_i(w)) \rightarrow \min_w;$$



$$\begin{aligned} Q(M) &= (1 - M)^2 \\ V(M) &= (1 - M)_+ \\ S(M) &= 2(1 + e^M)^{-1} \\ L(M) &= \log_2(1 + e^{-M}) \\ E(M) &= e^{-M} \end{aligned}$$


# Градиентный спуск

$$\mathbf{x}_{n+1} = \mathbf{x}_n - \gamma_n \nabla F(\mathbf{x}_n), \quad n \geq 0.$$



# Градиентный спуск

$$\mathbf{x}_{n+1} = \mathbf{x}_n - \gamma_n \nabla F(\mathbf{x}_n), \quad n \geq 0.$$



$$\nabla_w \tilde{Q} = \sum_{i=1}^l \nabla L(M_i)$$

$$\nabla \tilde{Q} = \sum_{i=1}^l L'(M_i) \frac{\partial M_i}{\partial w}$$

$$\frac{\partial M_i}{\partial w} = y_i x_i$$

$$\nabla \tilde{Q} = \sum_{i=1}^l y_i x_i L'(M_i)$$

$$w_{n+1} = w_n - \gamma_n \sum_{i=1}^l y_i x_i L'(M_i)$$



# Стохастический градиент

$$w_{n+1} = w_n - \gamma_n \sum_{i=1}^l y_i x_i L'(M_i)$$


$$w_{n+1} = w_n - \gamma_n y_i x_i L'(M_i)$$

$x_i$  — случайный элемент обучающей выборки

# Регуляризация


$$\sum_{i=1}^l L(M_i) + \gamma \sum_{k=1}^m |w_k| \rightarrow \min$$

$l1$  – регуляризация



$$\sum_{i=1}^l L(M_i) + \gamma \sum_{k=1}^m w_k^2 \rightarrow \min$$

$l2$  – регуляризация



# Общий случай

$$Q = \sum_{i=1}^{\ell} L(y_i, f(x_i)) + \gamma V(w) \rightarrow \min_w$$

Функция потерь

Коэффициент  
регуляризации

Регуляризатор

## II. Логистическая регрессия

# Логистическая регрессия

$$y_i \in \{0, 1\} \quad Q = - \sum_{i=1}^{\ell} y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \rightarrow \min_w$$

$$p_i = \sigma(\langle w, x_i \rangle) = \frac{1}{1 + e^{-\langle w, x_i \rangle}}$$

# Логистическая регрессия

$$y_i \in \{0, 1\} \quad Q = - \sum_{i=1}^{\ell} y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \rightarrow \min_w$$

$$p_i = \sigma(\langle w, x_i \rangle) = \frac{1}{1 + e^{-\langle w, x_i \rangle}} = P(y = 1|x)$$

# Логистическая регрессия

$$y_i \in \{0, 1\} \quad Q = - \sum_{i=1}^{\ell} y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \rightarrow \min_w$$

$$p_i = \sigma(\langle w, x_i \rangle) = \frac{1}{1 + e^{-\langle w, x_i \rangle}} = P(y = 1|x)$$

Как правило, добавляется  $\ell_1$  или  $\ell_2$ -регуляризация, а оптимизационная задача решается с помощью SGD или метода Ньютона-Рафсона

# Эквивалентность оптимизационных задач

$$Q = - \sum_{i=1}^{\ell} y_i \ln \frac{1}{1 + e^{-\langle w, x_i \rangle}} + (1 - y_i) \ln \frac{1}{1 + e^{\langle w, x_i \rangle}} \rightarrow \min_w$$

$$-y_i \ln \frac{1}{1 + e^{-\langle w, x_i \rangle}} - (1 - y_i) \ln \frac{1}{1 + e^{\langle w, x_i \rangle}} = \begin{cases} \ln(1 + e^{-\langle w, x_i \rangle}), & y_i = 1 \\ \ln(1 + e^{\langle w, x_i \rangle}), & y_i = 0 \end{cases}$$

$$Q = \sum_{i=1}^{\ell} \underbrace{\ln(1 + e^{-y_i \langle w, x_i \rangle})}_{L(M) = \ln(1 + e^{-M_i})} \rightarrow \min_w \quad y_i \in \{-1, 1\}$$



# Методы оптимизации

- SGD
- Метод Ньютона-Рафсона
- IRLS

### III. Метод опорных векторов

# Метод опорных векторов

Линейный классификатор:

$$a(x) = \text{sign}(\langle w, x \rangle - w_0)$$

Использующий кусочно-линейную функцию потерь и L2-регуляризатор:

$$\sum_{i=1}^l L(M_i) + \gamma \|w\|^2 \rightarrow \min_w$$


функция потерь

квадратичный регуляризатор


кусочно-линейная функция потерь:

$$L(M_i) = \max\{0, 1 - M_i\} = (1 - M_i)_+$$

# Построение разделяющей гиперплоскости




# Разделяющая полоса



$$a(x) = \text{sign} \left( \sum_{j=1}^n w_j x^j - w_0 \right) = \text{sign}(\langle w, x \rangle - w_0)$$


# Разделяющая полоса



$$\min_{i=1,\dots,\ell} y_i (\langle w, x_i \rangle - w_0) = 1.$$

$$a(x) = \text{sign} \left( \sum_{j=1}^n w_j x^j - w_0 \right) = \text{sign} (\langle w, x \rangle - w_0).$$


# Ширина разделяющей полосы



$$\min_{i=1,\dots,\ell} y_i (\langle w, x_i \rangle - w_0) = 1.$$

$$\left\langle (x_+ - x_-), \frac{w}{\|w\|} \right\rangle$$

# Ширина разделяющей полосы




$$\min_{i=1,\dots,\ell} y_i (\langle w, x_i \rangle - w_0) = 1.$$

$$\left\langle (x_+ - x_-), \frac{w}{\|w\|} \right\rangle = \frac{\langle w, x_+ \rangle - \langle w, x_- \rangle}{\|w\|}$$




# Ширина разделяющей полосы



$$\min_{i=1,\dots,\ell} y_i (\langle w, x_i \rangle - w_0) = 1.$$

$$\left\langle (x_+ - x_-), \frac{w}{\|w\|} \right\rangle = \frac{\langle w, x_+ \rangle - \langle w, x_- \rangle}{\|w\|} = \frac{(w_0 + 1) - (w_0 - 1)}{\|w\|} = \frac{2}{\|w\|}$$


# Ширина разделяющей полосы



$$\min_{i=1,\dots,\ell} y_i (\langle w, x_i \rangle - w_0) = 1.$$

$$\left\langle (x_+ - x_-), \frac{w}{\|w\|} \right\rangle = \frac{\langle w, x_+ \rangle - \langle w, x_- \rangle}{\|w\|} = \frac{(w_0 + 1) - (w_0 - 1)}{\|w\|} = \frac{2}{\|w\|}$$

# Максимизация зазора




$$\min_{i=1,\dots,\ell} y_i (\langle w, x_i \rangle - w_0) = 1.$$

$$\left\langle (x_+ - x_-), \frac{w}{\|w\|} \right\rangle = \frac{\langle w, x_+ \rangle - \langle w, x_- \rangle}{\|w\|} = \frac{(w_0 + 1) - (w_0 - 1)}{\|w\|} = \frac{2}{\|w\|}$$

$$\begin{cases} \langle w, w \rangle \rightarrow \min; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1, \quad i = 1, \dots, \ell. \end{cases}$$

# Случай линейно неразделимой выборки



$$\begin{cases} \langle w, w \rangle \rightarrow \min; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1, \quad i = 1, \dots, \ell \end{cases}$$

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w, w_0, \xi}; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, \ell; \\ \xi_i \geq 0, \quad i = 1, \dots, \ell. \end{cases}$$

# Оптимизационная задача в SVM

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w, w_0, \xi}; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, \ell; \\ \xi_i \geq 0, \quad i = 1, \dots, \ell. \end{cases}$$

Причем здесь линейный классификатор  
в привычном нам виде?

# Безусловная оптимизационная задача в SVM

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w, w_0, \xi}; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, \ell; \\ \xi_i \geq 0, \quad i = 1, \dots, \ell. \end{cases}$$

Напоминание:

$$M_i = y_i (\langle w, x_i \rangle - w_0)$$

отступ на  $i$ -том объекте

# Безусловная оптимизационная задача в SVM

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w, w_0, \xi}; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, \ell; \\ \xi_i \geq 0, \quad i = 1, \dots, \ell. \end{cases}$$

Напоминание:

$$M_i = y_i (\langle w, x_i \rangle - w_0)$$

отступ на  $i$ -том объекте

$$\xi_i \geq 0$$

$$\xi_i \geq 1 - M_i$$

$$\sum_{i=1}^{\ell} \xi_i \rightarrow \min$$

# Безусловная оптимизационная задача в SVM

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w, w_0, \xi}; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, \ell; \\ \xi_i \geq 0, \quad i = 1, \dots, \ell. \end{cases}$$

Напоминание:

$$M_i = y_i (\langle w, x_i \rangle - w_0)$$

отступ на  $i$ -том объекте

$$\xi_i \geq 0$$

$$\xi_i \geq 1 - M_i$$

$$\Rightarrow \xi_i = \max\{0, 1 - M_i\} = (1 - M_i)_+$$

$$\sum_{i=1}^{\ell} \xi_i \rightarrow \min$$



# Безусловная оптимизационная задача в SVM

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w, w_0, \xi}; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, \ell; \\ \xi_i \geq 0, \quad i = 1, \dots, \ell. \end{cases}$$

Напоминание:

$$M_i = y_i (\langle w, x_i \rangle - w_0)$$

отступ на  $i$ -том объекте

$$\xi_i \geq 0$$

$$\xi_i \geq 1 - M_i$$

$$\Rightarrow \xi_i = \max\{0, 1 - M_i\} = (1 - M_i)_+$$

$$\sum_{i=1}^{\ell} \xi_i \rightarrow \min$$

$$Q(w, w_0) = \sum_{i=1}^{\ell} (1 - M_i(w, w_0))_+ + \frac{1}{2C} \|w\|^2 \rightarrow \min_{w, w_0}$$

## Безусловная оптимизационная задача в SVM


$$Q(w, w_0) = \sum_{i=1}^{\ell} (1 - M_i(w, w_0))_+ + \frac{1}{2C} \|w\|^2 \rightarrow \min_{w, w_0}$$

---

# Ключевые моменты

- Метод опорных векторов – линейный классификатор с кусочно-линейной функцией потерь (hinge loss) и L2-регуляризатором
- Придуман метод был из соображений максимизации зазора между классами
- В случае линейно разделимой выборки это означает просто максимизацию ширины разделяющей полосы
- А в случае линейно неразделимой выборки просто добавляется возможность попадания объектов в полосу и штрафы за эти попадания

# Добавление новых признаков



$$\phi : (x_1, x_2) \longrightarrow (x_1^2, \sqrt{2}x_1x_2, x_2^2)$$

$$\left(\frac{x_1}{a}\right)^2 + \left(\frac{x_2}{b}\right)^2 = 1 \longrightarrow \frac{z_1}{a^2} + \frac{z_3}{b^2} = 1$$

Спрямляющее  
пространство


# Kernel Trick

$$\begin{array}{l} x \mapsto \phi(x) \\ w \mapsto \phi(w) \end{array} \Rightarrow \langle w, x \rangle \mapsto \langle \phi(w), \phi(x) \rangle$$

Можно не делать преобразование признаков явно, а вместо скалярного произведения  $\langle w, x \rangle$  использовать функцию  $K(w, x)$ , представимую в виде:


$$K(w, x) = \langle \phi(w), \phi(x) \rangle$$

# Линейное ядро



$$K(w, x) = \langle w, x \rangle$$


# Полиномиальное ядро



$$K(w, x) = (\gamma < w, x > + r)^d$$

<https://youtu.be/3liCbRZPrZA>

# Радиальное ядро



$$K(w, x) = e^{-\gamma \|w - x\|^2}$$




# Ядра и библиотеки

- LibSVM – можно выбирать ядра
- LibLinear – только линейное ядро
- Scikit-learn – обертка над LibSVM и LibLinear
- Vowpal Wabbit – только линейное ядро


Напоминание: теорема Каруша-Куна-Таккера

$$\begin{cases} f(x) \rightarrow \min_x \\ g(x) \leq 0 \end{cases} \implies \begin{cases} \nabla_x L(x, \mu) = \nabla_x (f(x) + \mu g(x)) = 0 \\ \mu g(x) = 0 \\ \mu \geq 0 \end{cases}$$

# Напоминание: теорема Каруша-Куна-Таккера



# Напоминание: теорема Каруша-Куна-Таккера



# Двойственная задача в SVM

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w, w_0, \xi}; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, \ell; \\ \xi_i \geq 0, \quad i = 1, \dots, \ell. \end{cases}$$

# Двойственная задача в SVM

$$\left\{ \begin{array}{l} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w, w_0, \xi}; \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, \quad i = 1, \dots, \ell; \\ \xi_i \geq 0, \quad i = 1, \dots, \ell. \end{array} \right.$$

$$M_i(w, w_0) = y_i (\langle w, x_i \rangle - w_0)$$

# Двойственная задача в SVM

$$\begin{cases} \frac{1}{2} \langle w, w \rangle + C \sum_{i=1}^{\ell} \xi_i \rightarrow \min_{w, w_0, \xi}; & M_i(w, w_0) = y_i (\langle w, x_i \rangle - w_0) \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - \xi_i, & i = 1, \dots, \ell; \\ \xi_i \geq 0, & i = 1, \dots, \ell. \end{cases}$$

$$\begin{aligned} \mathcal{L}(w, w_0, \xi; \lambda, \eta) &= \frac{1}{2} \|w\|^2 + C \sum_{i=1}^{\ell} \xi_i - \sum_{i=1}^{\ell} \lambda_i (M_i(w, w_0) - 1 + \xi_i) - \sum_{i=1}^{\ell} \xi_i \eta_i = \\ &= \frac{1}{2} \|w\|^2 - \sum_{i=1}^{\ell} \lambda_i (M_i(w, w_0) - 1) - \sum_{i=1}^{\ell} \xi_i (\lambda_i + \eta_i - C), \end{aligned}$$

# Двойственная задача в SVM

$$\begin{aligned}\mathcal{L}(w, w_0, \xi; \lambda, \eta) &= \frac{1}{2}\|w\|^2 + C \sum_{i=1}^{\ell} \xi_i - \sum_{i=1}^{\ell} \lambda_i (M_i(w, w_0) - 1 + \xi_i) - \sum_{i=1}^{\ell} \xi_i \eta_i = \\ &= \frac{1}{2}\|w\|^2 - \sum_{i=1}^{\ell} \lambda_i (M_i(w, w_0) - 1) - \sum_{i=1}^{\ell} \xi_i (\lambda_i + \eta_i - C),\end{aligned}$$

$$\begin{cases} \mathcal{L}(w, w_0, \xi; \lambda, \eta) \rightarrow \min_{w, w_0, \xi} \max_{\lambda, \eta}; \\ \xi_i \geq 0, \quad \lambda_i \geq 0, \quad \eta_i \geq 0, \quad i = 1, \dots, \ell; \\ \lambda_i = 0 \text{ либо } M_i(w, w_0) = 1 - \xi_i, \quad i = 1, \dots, \ell; \\ \eta_i = 0 \text{ либо } \xi_i = 0, \quad i = 1, \dots, \ell; \end{cases}$$



# Опорные векторы в SVM

$$\begin{aligned}\mathcal{L}(w, w_0, \xi; \lambda, \eta) &= \frac{1}{2}\|w\|^2 + C \sum_{i=1}^{\ell} \xi_i - \sum_{i=1}^{\ell} \lambda_i (M_i(w, w_0) - 1 + \xi_i) - \sum_{i=1}^{\ell} \xi_i \eta_i = \\ &= \frac{1}{2}\|w\|^2 - \sum_{i=1}^{\ell} \lambda_i (M_i(w, w_0) - 1) - \sum_{i=1}^{\ell} \xi_i (\lambda_i + \eta_i - C),\end{aligned}$$

$$\frac{\partial \mathcal{L}}{\partial w} = w - \sum_{i=1}^{\ell} \lambda_i y_i x_i = 0 \quad \implies \quad w = \sum_{i=1}^{\ell} \lambda_i y_i x_i;$$

## Двойственная задача: итог

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = -\lambda_i - \eta_i + C = 0 \quad \implies \quad \eta_i + \lambda_i = C, \quad i = 1, \dots, \ell.$$

$$\left\{ \begin{array}{l} -\mathcal{L}(\lambda) = -\sum_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j \langle x_i, x_j \rangle \rightarrow \min_{\lambda}; \\ 0 \leq \lambda_i \leq C, \quad i = 1, \dots, \ell; \\ \sum_{i=1}^{\ell} \lambda_i y_i = 0. \end{array} \right.$$


# Вид классификатора в SVM

$$a(x) = \text{sign} \left( \sum_{i=1}^{\ell} \lambda_i y_i \langle x_i, x \rangle - w_0 \right)$$

Вид классификатора в SVM: теперь с ядром


$$a(x) = \text{sign} \left( \sum_{i=1}^h \lambda_i y_i K(x_i, x) - w_0 \right)$$

# Линейная регрессия



$$Q(a, X^\ell) = \sum_{i=1}^{\ell} (\langle w, x_i \rangle - w_0 - y_i)^2 + \tau \|w\|^2 \rightarrow \min_{w, w_0}$$

# SVM для регрессии



$$Q_{\varepsilon}(a, X^{\ell}) = \sum_{i=1}^{\ell} |\langle w, x_i \rangle - w_0 - y_i|_{\varepsilon} + \tau \langle w, w \rangle^2 \rightarrow \min_{w, w_0}$$

## IV. Подробнее о регуляризации


Почему  $\ell_1$  разреживает: простое и  
неубедительно объяснение

$$\left\{ \begin{array}{l} \tilde{Q} = \sum_{i=1}^l L(M_i) \rightarrow \min \\ \sum_{k=1}^m |w_k| \leq \tau \end{array} \right.$$



Почему  $\ell_1$  разреживает: простое и  
неубедительно объяснение

$$\left\{ \begin{array}{l} \tilde{Q} = \sum_{i=1}^l L(M_i) \rightarrow \min \\ \sum_{k=1}^m |w_k| \leq \tau \end{array} \right.$$



# Вероятностный смысл регуляризаторов

$$Q = \sum_{i=1}^{\ell} L(y_i, f(x_i)) + \gamma V(w) \rightarrow \min_w$$

# Вероятностный смысл регуляризаторов

$$Q = \sum_{i=1}^{\ell} L(y_i, f(x_i)) + \gamma V(w) \rightarrow \min_w$$
$$\sum_{i=1}^{\ell} -L(y_i, f(x_i)) - \gamma V(w) \rightarrow \max_w$$

# Вероятностный смысл регуляризаторов

$$Q = \sum_{i=1}^{\ell} L(y_i, f(x_i)) + \gamma V(w) \rightarrow \min_w$$

$$\sum_{i=1}^{\ell} -L(y_i, f(x_i)) - \gamma V(w) \rightarrow \max_w$$

$$\sum_{i=1}^{\ell} \ln e^{-L(y_i, f(x_i))} + \ln e^{-\gamma V(w)} \rightarrow \max_w$$

# Вероятностный смысл регуляризаторов

$$Q = \sum_{i=1}^{\ell} L(y_i, f(x_i)) + \gamma V(w) \rightarrow \min_w$$

$$\sum_{i=1}^{\ell} -L(y_i, f(x_i)) - \gamma V(w) \rightarrow \max_w$$

$$\sum_{i=1}^{\ell} \ln e^{-L(y_i, f(x_i))} + \ln e^{-\gamma V(w)} \rightarrow \max_w$$

$$e^{-\gamma V(w)} \prod_{i=1}^{\ell} e^{-L(y_i, f(x_i))} \rightarrow \max_w$$

# Вероятностный смысл регуляризаторов

$$Q = \sum_{i=1}^{\ell} L(y_i, f(x_i)) + \gamma V(w) \rightarrow \min_w$$

$$\sum_{i=1}^{\ell} -L(y_i, f(x_i)) - \gamma V(w) \rightarrow \max_w$$

$$\sum_{i=1}^{\ell} \ln e^{-L(y_i, f(x_i))} + \ln e^{-\gamma V(w)} \rightarrow \max_w$$

$$P(w) \sim \boxed{e^{-\gamma V(w)}} \prod_{i=1}^{\ell} e^{-L(y_i, f(x_i))} \rightarrow \max_w$$

# Вероятностный смысл регуляризаторов

$$Q = \sum_{i=1}^{\ell} L(y_i, f(x_i)) + \gamma V(w) \rightarrow \min_w$$

$$\sum_{i=1}^{\ell} -L(y_i, f(x_i)) - \gamma V(w) \rightarrow \max_w$$

$$\sum_{i=1}^{\ell} \ln e^{-L(y_i, f(x_i))} + \ln e^{-\gamma V(w)} \rightarrow \max_w$$

$$P(w) \sim e^{-\gamma V(w)} \prod_{i=1}^{\ell} e^{-L(y_i, f(x_i))} \sim P(x_i, y_i | w)$$

# Вероятностный смысл регуляризаторов

- $\ell_2$  — гауссовский регуляризатор
- $\ell_1$  — лапласовский регуляризатор

Упражнение:

Покажите связь этих регуляризаторов с заявленными распределениями



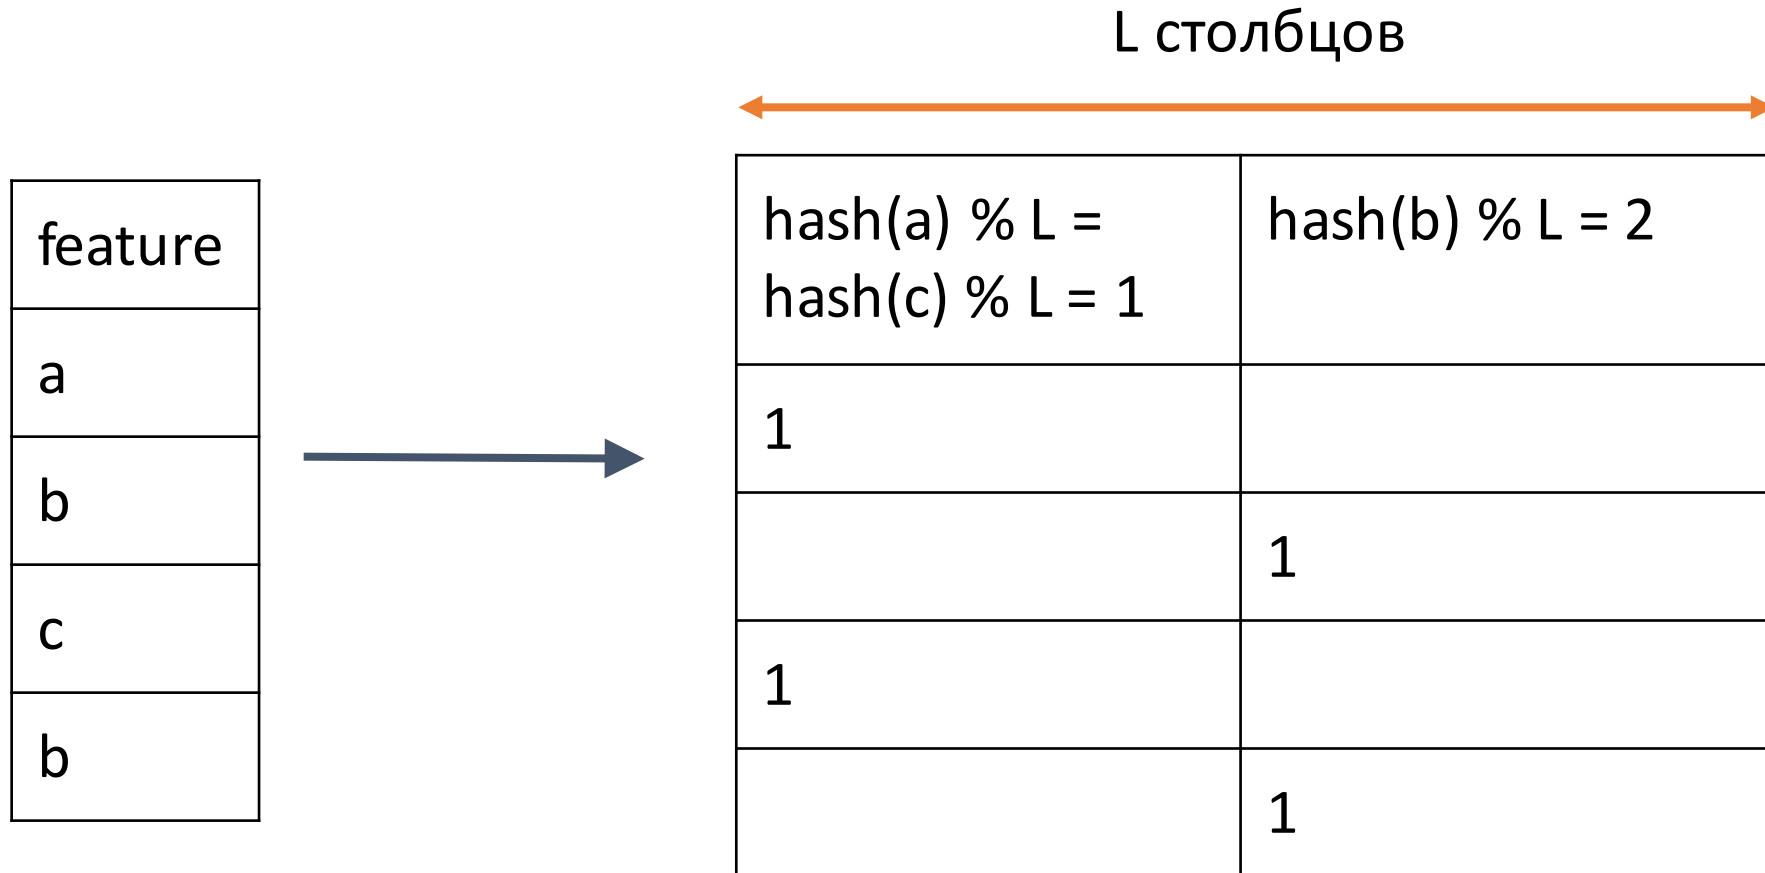
V. Где применяют линейные  
модели

# Классификация текстов



|          |   |
|----------|---|
| aardvark | 0 |
| about    | 2 |
| all      | 2 |
| Africa   | 1 |
| apple    | 0 |
| anxious  | 0 |
| ...      |   |
| gas      | 1 |
| ...      |   |
| oil      | 1 |
| ...      |   |
| Zaire    | 0 |

# Напоминание: hashing trick



# Обработка разреженных признаков

Часть признаков – разреженные, а часть – плотные, как быть?

- Строим на разреженных признаках линейную модель
- Ответ линейной модели добавляем как еще один плотный признак
- Либо строим на плотных признаках другую модель и усредняем с ней

# Простые модели сложных систем


- Прогнозирование охвата целевой аудитории по параметрам рекламной кампании
- Прогнозирование дефектов в продукции на заводе
- Прогнозирование хим. состава в результате сложного процесса производства

*Как правило – везде сложные зависимости от большого числа параметров, но не все параметры известны и мало точек*


# ОТЗЫВЫ

Отзывы о прошедших лекциях и семинарах можно и нужно оставлять здесь:

<https://ml-mipt.github.io/2017part1/>



# DeepBayes Summer School



- Самые продвинутые нейросеточки
- Зачем там байесовские методы?
- Будут ли на школе кормить? Да :)

**Deadline 31 Марта**  
**Есть тестовое задание**

**26-30 Августа, [deepbayes.ru](http://deepbayes.ru)**

